Методика приоритизации уточнений при оценке виртуального ассистента

Как из вероятностной оценки сложности получить ожидаемую трудоемкость, риск и приоритет вопросов заказчику

Короткая идея. Для каждого компонента мы переводим категории Zero / Small / Medium / Large в возможные человеко-дни, считаем не только среднее значение, но и разброс возможной трудоемкости. Чем больше этот разброс и чем дешевле его снять уточнением, тем выше приоритет вопроса заказчику.

1. Исходные данные

Для каждого компонента системы задаются четыре величины:

- Распределение оценки сложности p = [pZero, pSmall, pMedium, pLarge]. Например, [0.5, 0.3, 0.1, 0.1]. Сумма вероятностей всегда равна 1.
- Коэффициент трудоемкости k. Он задает масштаб компонента в человеко-днях.
- Prior по компоненту q. Он используется, когда в ТЗ нет информации о компоненте или информации недостаточно для содержательной оценки.
- Стоимость уточнения c. Это относительная цена получения более точной информации у заказчика.

Категории сложности и их базовые веса:

Категория	Вес	Смысл
Zero	0	Компонент не требуется.
Small	1	Простая типовая реализация.
Medium	3	Заметная кастомизация / интеграция / дополнительные требования.
Large	10	Сложная кастомная реализация, high-load, on-prem, дообучение, высокие SLA и т.п.

Вектор весов: w = [0, 1, 3, 10]

2. Как использовать prior

Prior - это исходное ожидание до чтения конкретного ТЗ. Для разных компонентов он может быть разным. Например, отсутствие упоминания fine-tuning обычно сильнее говорит о том, что он не нужен, чем отсутствие подробностей о web-интерфейсе.

Если для компонента задан свой prior, используем его. Если prior неизвестен, используем значение по умолчанию:

```
q_default = [0.50, 0.30, 0.15, 0.05]
```

Практическое правило:

- Если в ТЗ нет информации по компоненту, текущим распределением оценки сложности становится prior: p = q.

- Если в ТЗ есть явная информация, формируем новое распределение p на основе этой информации. Например, если явно сказано, что используется стандартный SaaS STT, можно получить p = [0, 1, 0, 0].
- Если информация частичная, p остается распределением, например [0.1, 0.6, 0.25, 0.05]. Prior при этом служит исходной точкой, а не отдельным множителем в финальной формуле.

Важно: не следует одновременно подставлять и p, и prior в формулу риска. Если p уже является текущей оценкой с учетом ТЗ и prior, то все дальнейшие расчеты делаются по p.

3. Перевод сложности в человеко-дни

Для компонента с коэффициентом трудоемкости k сначала определим четыре фиксированных возможных значения трудоемкости - по одному для каждой категории:

d_i = k * w_i, то есть [d_Zero, d_Small, d_Medium, d_Large] = k * [0, 1, 3, 10]

Например, если k = 5:

[d_Zero, d_Small, d_Medium, d_Large] = [0, 5, 15, 50] человеко-дней

То есть если истинная категория окажется Zero, компонент потребует 0 дней; если Small - примерно 5; если Medium - примерно 15; если Large - примерно 50. Эти четыре числа сами по себе являются фиксированными сценариями, а не случайной величиной.

Ключевое различие обозначений: d_i - фиксированные значения для четырех сценариев, а D - случайная величина. Распределение D задается вероятностями p_i: P(D = d_i) = p_i.

Например, при p = [0, 1, 0, 0] величина D всегда равна d_Small, поэтому sigma(D) = 0. При p = [0.5, 0, 0, 0.5] D с вероятностью 0.5 равна d_Zero и с вероятностью 0.5 равна d_Large, поэтому разброс велик.

4. Ожидаемая трудоемкость

Теперь вводим случайную величину D - фактическую трудоемкость компонента. Она принимает значение d_i с вероятностью p_i: P(D = d_i) = p_i. Именно поэтому все последующие показатели зависят от распределения оценки сложности p.

E[D] = mu = sum(p_i * d_i)

Пример. Пусть:

p = [0.5, 0.3, 0.1, 0.1]
k = 5
[d_i] = [0, 5, 15, 50]
P(D = d_i) = p_i

```
mu = 0.5*0 + 0.3*5 + 0.1*15 + 0.1*50 = 8 человеко-дней
```

Это полезная оценка бюджета, но она сама по себе не говорит, насколько мы уверены в этих 8 днях.

5. Неопределенность в человеко-днях

Для приоритизации уточнений лучше измерять не энтропию категорий, а разброс возможной трудоемкости. Используем стандартное отклонение стоимости компонента:

$$U = \sigma(D) = \sqrt{\sum p_i \cdot (d_i - \mu)^2}$$

U измеряется прямо в человеко-днях. Если p сосредоточено в одной категории, U = 0. Если заметная вероятность распределена между сильно различающимися по трудоемкости категориями, U становится большим.

Почему не энтропия? Энтропия видит только распределение вероятностей и не знает, насколько уровни отличаются по стоимости. Например, [0.5, 0, 0, 0.5] и [0, 0.5, 0.5, 0] имеют одинаковую энтропию, но в первом случае неопределенность между 0 и Large, а во втором - только между Small и Medium. Для бюджета это принципиально разные риски.

Так как $d_i = k \cdot w_i$, формулу неопределенности можно записать компактнее через веса категорий:

$$U = k \cdot \sqrt{\sum p_i \cdot (w_i - m_w)^2}, \text{ где } m_w = \sum(p_i \cdot w_i)$$

Здесь зависимость от p явная: и средний вес m_w, и сам взвешенный разброс считаются с вероятностями p_i. Коэффициент трудоемкости k уже автоматически масштабирует неопределенность в человеко-дни, поэтому дополнительно умножать U на k не нужно.

6. Базовый приоритет уточнения

Если предположить, что один хороший вопрос полностью выясняет уровень компонента, после ответа неопределенность по этому компоненту становится близкой к нулю. Тогда ожидаемая ценность уточнения приблизительно равна текущей неопределенности:

```
RawPriority = U
```

Иными словами: сначала стоит уточнять те компоненты, по которым возможный разброс человеко-дней максимален.

7. Учет стоимости уточнения

Не все неопределенности одинаково легко снять. Один вопрос можно задать бизнес-заказчику за минуту, другой требует отдельной встречи с ИБ, а третий - исследования или PoC.

Предлагаемая шкала стоимости уточнения:

c	Тип уточнения	Пример
1	Простой вопрос заказчику	"Нужен ли голосовой ввод?"
2	Требуется обсуждение	Нужно совместно уточнить несколько сценариев и ограничений.
4	Нужен архитектор / ИБ / инфраструктура	Требования к on-prem, SSO, сетевым зонам, аудиту.
8	Исследование или PoC	Качество редкого языка, нагрузочный эксперимент, проверка дообучения.

Рекомендация: оставить степенную шкалу 1 / 2 / 4 / 8 как описание реальной стоимости получения информации, но не делить RawPriority прямо на c. Прямое деление слишком агрессивно штрафует сложные вопросы.

Для основной методики используем мягкий штраф:

```
PriorityScore = U / sqrt(c)
```

Тогда относительные штрафы для c = 1 / 2 / 4 / 8 будут примерно 1 / 1.41 / 2 / 2.83. Сложное уточнение по-прежнему опускается в рейтинге, но не исчезает из него только потому, что требует эксперта или PoC.

Если задача другая - например, за один короткий созвон снять максимум неопределенности дешевыми вопросами - можно использовать более жесткий вариант:

```
EfficiencyScore = U / c
```

Он интерпретируется как количество снимаемой неопределенности на единицу усилий по уточнению.

8. Итоговые показатели для каждого компонента

Для каждого компонента рекомендуется рассчитывать минимум четыре показателя:

Показатель	Формула	Единица	Что означает
Expected Effort	mu = sum(p_i * D_i)	чел.-дни	Текущая средняя оценка трудоемкости.
Uncertainty	U = sqrt(sum(p_i*(D_i-mu)^2))	чел.-дни	Насколько сильно может измениться оценка из-за неизвестности.
Raw Priority	U	чел.-дни	Ценность уточнения, если вопрос почти полностью снимает неопределенность.
Priority Score	U / sqrt(c)	условный score	Основной рейтинг вопросов с мягким учетом стоимости уточнения.

Основной score для сортировки: PriorityScore = U / sqrt(c). Чем он выше, тем раньше стоит уточнять компонент.

9. Полный пример

Предположим, оценивается компонент "Голосовой ввод".

- Коэффициент трудоемкости: k = 3.
- Веса уровней: w = [0, 1, 3, 10].
- Фиксированные сценарии трудозатрат: [d_i] = [0, 3, 9, 30]. Случайная величина D принимает эти значения с вероятностями p_i.
- После чтения ТЗ получено распределение оценки сложности p = [0.5, 0.3, 0.1, 0.1].
- Стоимость уточнения c = 1, потому что достаточно спросить, нужен ли on-prem и есть ли специфический язык/лексика.

Шаг 1. Ожидаемая трудоемкость:

```
mu = 0.5*0 + 0.3*3 + 0.1*9 + 0.1*30 = 4.8 чел.-дня
```

Шаг 2. Неопределенность:

```
U = sqrt(0.5*(0-4.8)^2 + 0.3*(3-4.8)^2 + 0.1*(9-4.8)^2 + 0.1*(30-4.8)^2)
U ≈ 9.1 чел.-дня
```

Шаг 3. Приоритет с учетом стоимости уточнения:

```
PriorityScore = 9.1 / sqrt(1) = 9.1
```

Теперь сравним с другим компонентом, у которого U = 12 чел.-дней, но для уточнения нужен PoC с c = 8:

```
PriorityScore = 12 / sqrt(8) ≈ 4.24
```

Несмотря на более высокую исходную неопределенность, этот вопрос может идти позже, потому что получить ответ существенно дороже.

10. Что делать, если ТЗ вообще ничего не говорит о компоненте

Допустим, для компонента не задан специальный prior и в ТЗ нет никакой информации. Тогда:

```
p = q_default = [0.50, 0.30, 0.15, 0.05]
```

Дальше расчет полностью обычный: строим D из коэффициента трудоемкости, считаем mu, U и PriorityScore. Поэтому компонент, который вообще не упомянут в ТЗ, не получает автоматически максимальную неопределенность: модель учитывает, что при отсутствии упоминания Zero и Small априори вероятнее, чем Large.

11. Дополнительный показатель: риск дорогого сценария

Для пресейла иногда полезно отдельно видеть не только разброс, но и риск неприятного дорогого сценария. Для этого можно показывать высокий квантиль, например P90: минимальное значение D, ниже которого лежит не менее 90% вероятности.

```
TailRisk = P90(D) - mu
```

TailRisk не обязательно использовать в основном рейтинге вопросов, но он хорошо показывает компоненты, где средняя оценка выглядит умеренной, а небольшой шанс Large резко увеличивает потенциальный бюджет.

12. Рекомендуемый алгоритм

1. Для каждого компонента взять его коэффициент трудоемкости k.

2. Получить текущее распределение оценки сложности p из ТЗ. Если информации нет - взять prior компонента; если он неизвестен - [0.50, 0.30, 0.15, 0.05].

3. Рассчитать четыре возможных значения трудоемкости: d_i = k * w_i, то есть [d_i] = k * [0, 1, 3, 10]. Считать D случайной величиной с P(D = d_i) = p_i.

4. Посчитать ожидаемую трудоемкость mu.

5. Посчитать неопределенность U = sigma(D), используя вероятности p_i и возможные значения d_i.

6. Взять стоимость уточнения c; если она не задана - c = 2.

7. Посчитать PriorityScore = U / sqrt(c).

8. Отсортировать компоненты по PriorityScore по убыванию и начать уточнение с верхних позиций.

9. После каждого ответа заказчика обновить p и пересчитать рейтинг: приоритеты следующих вопросов могут существенно измениться.

13. Формулы в одном месте

Категории:

```
w = [0, 1, 3, 10]  для [Zero, Small, Medium, Large]
```

Prior по умолчанию:

```
q_default = [0.50, 0.30, 0.15, 0.05]
```

Если информации по компоненту нет:

```
p = q_component, а если q_component неизвестен, p = q_default
```

Возможные значения человеко-дней для категорий:

d_i = k * w_i

Ожидаемая трудоемкость:

mu = E[D] = sum(p_i * d_i)

Неопределенность:

U = sigma(D) = sqrt(sum(p_i * (d_i - mu)^2))

Таким образом, U зависит от p напрямую: вероятности p_i входят в формулу как веса возможных сценариев d_i.

Стоимость уточнения по умолчанию:

```
c_default = 2
```

Основной приоритет:

```
PriorityScore = U / sqrt(c)
```

Альтернативный жесткий score для дешевых быстрых уточнений:

```
EfficiencyScore = U / c
```

Опциональный tail risk:

```
TailRisk = P90(D) - mu
```

Интерпретация результата. Expected Effort отвечает на вопрос «сколько в среднем добавляет компонент при текущем распределении p». Uncertainty отвечает на вопрос «насколько широко разбросаны возможные человеко-дни с учетом p». PriorityScore отвечает на вопрос «какой компонент выгоднее всего уточнить следующим с учетом цены получения ответа».